

SBT ML2017, Задание 1

Жакиянова Меруерт

April 2017

1 Наивный байес и центроидный классификатор

$$P(x^{(k)}|y) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x^{(k)} - \mu_{yk})^2}{2\sigma^2}\right)$$

$$\begin{aligned} a(x) &= \arg \max_y P(y) \prod_{k=1}^n P(x^{(k)}|y) = \arg \max_y [\ln[P(y) \prod_{k=1}^n P(x^{(k)}|y)]] = \\ &= \arg \max_y [\ln[P(y) + \sum_{k=1}^n \ln[(\frac{1}{\sqrt{2\pi\sigma^2}} \exp(-\frac{(x^{(k)} - \mu_{yk})^2}{2\sigma^2}))]]] = \arg \max_y [\ln[P(y) + \\ &= \sum_{k=1}^n \ln[\frac{1}{\sqrt{2\pi\sigma^2}}] + \sum_{k=1}^n (-\frac{(x^{(k)} - \mu_{yk})^2}{2\sigma^2})] = \arg \max_y [\ln[P(y) + n \ln[\frac{1}{\sqrt{2\pi\sigma^2}}] + \sum_{k=1}^n (-\frac{(x^{(k)} - \mu_{yk})^2}{2\sigma^2})]] = \\ &= \arg \max_y [\ln[P(y) + n \ln[\frac{1}{\sqrt{2\pi\sigma^2}}] - \frac{1}{2\sigma^2} \sum_{k=1}^n (x^{(k)} - \mu_{yk})^2]] \end{aligned}$$

Классы имеют одинаковые априорные вероятности $\Rightarrow P(y) = \text{const}$ и $a(x) = \arg \min_y \frac{1}{2\sigma^2} \sum_{k=1}^n (x^{(k)} - \mu_{yk})^2 = \arg \min_y \|x - \mu_y\|$
Получаем центроидный классификатор.

2 Ошибка 1NN и оптимального байесовского классификатора

Вероятность ошибки байесовского классификатора:

$$E_B = \min\{P(1|x); P(0|x)\} = 1 - \max_{y \in \{0,1\}} P(y|x)$$

Пусть $r = \max_{y \in \{0,1\}} P(y|x)$

Ошибка метода ближайшего соседа $E_{N,n} = P(y \neq y_n)$. При $n \rightarrow \infty$ распределение вероятностей классов для ближайшего соседа $x - \{P(y_n|x_n)\}_{y_n=0}^1$ стремится к распределению для x : $\{P(y|x)\}_{y=0}^1$.

$$\begin{aligned} E_{N,n} &= |\text{независимость принадлежностей классов для } x \text{ и } x_n| = \sum_{y \neq y_n \in \{0,1\}} P(y|x) P(y_n|x_n) \rightarrow \\ &= \sum_{y \in \{0,1\}} P(y|x) (1 - P(y|x)) = 2r(1 - r) \leq 2(1 - r) = 2E_B \end{aligned}$$